


## PRZYKŁAD DO PONIŻSZEGO

$$f(x, y) = \begin{cases} 12xy, & 0 \leq x \leq 1 \\ & 0 \leq y \leq x^2 \\ 0 & \text{poza} \end{cases}$$



$$f_x(x) = \begin{cases} 6x^5 & x \in (0, 1) \\ 0 & \text{poza} \end{cases}$$

## KRZYWA REGRESJI

- $(X, Y)$  -  $X, Y$  zmienne losowe niezależne
- $f(X, Y)$  - gęstość łączna
- gęstość warunkową zmiennej losowej  $Y$  gdy  $X = x$  nazywamy funkcją

$$f_{(Y|X)}(y|x) = \frac{f(x, y)}{f_x(x)}$$

- WARUNKOWĄ WARTOŚCIĄ OCZEKIWANĄ zmiennej losowej  $Y$  względem  $X$ , gdy  $X = x$  nazywamy liczbą

$$E(Y|X=x) = \int_{-\infty}^{\infty} y f_{(Y|X)}(y|x) dy$$

zależną od  $X$

- FUNKCJA REGRESJI (zmiennej losowej  $Y$  względem  $X$ ) nazywamy funkcją

$$m_y(x) = E(Y|X=x)$$

- jeżeli  $X, Y$  są niezależne, to  $E(Y|X=x) = EY$  dla każdego  $x$
- dla dowolnej funkcji  $h(x)$  zachodzi

$$\min E(Y - h(X))^2 = E(Y - E(Y|X))^2$$

- PRZYKŁAD: Wyznaczyć funkcję regresji zmiennej losowej  $Y$  względem zmiennej losowej  $X$  dla danych z ostatniego przykładu

$$f_{(Y|X)}(y|x) = \frac{f(x, y)}{f_x(x)} = \frac{12xy}{6x^5} = \frac{2y}{x^4} \quad (x, y) \in D \quad x \neq 0$$

$$E(Y|X=x) = \int_{-\infty}^{\infty} y f_{(Y|X)}(y|x) dy = \int_0^{x^2} y \frac{2y}{x^4} dy = \frac{2}{x^4} \cdot \frac{y^3}{3} \Big|_{y=0}^{y=x^2} = \frac{2}{x^4} \left( \frac{x^6}{3} - 0 \right) = \frac{2}{3} x^2$$

$$m_y(x) = \begin{cases} \frac{2}{3} x^2 & x \in (0, 1) \\ 0 & \text{poza} \end{cases}$$

$$m_y(x) = \begin{cases} \frac{2}{3}x^2 & x \in (0,1) \\ 0 & \text{poza} \end{cases}$$

$$\text{np dla } x = \frac{1}{2} \rightarrow m_y(x) = m_y\left(\frac{1}{2}\right) = \frac{2}{3} \left(\frac{1}{2}\right)^2 = \frac{1}{6}$$

## WSTĘPNA ANALIZA DANYCH STATYSTYCZNYCH

- PRÓBA PROSTA LOSOWA długości  $n$  ( $n \in \mathbb{N}$ ) to układ  $n$  niezależnych zmiennych losowych o jednakowym rozkładzie

$(X_1, X_2, \dots, X_n)$ ,  $X_k, k=1, \dots, n$  - taki sam rozkład prawdopodobieństwa

$(x_1, x_2, \dots, x_n)$   $x_n$  - obserwacja (realizacja) próby losowej  $(X_1, \dots, X_n)$

- PRZYKŁAD: w jednakowych 27 próbkach dielektryka określono zawartość tytanianu baru i otrzymano następujące wyniki (w mg):

$x_1$  8.31, 8.33, 8.36, 8.41, 8.42, 8.42, 8.44, 8.46, 8.47,  
8.48, 8.48, 8.48, 8.48, 8.49, 8.50, 8.50, 8.50, 8.51,  
8.55, 8.56, 8.58, 8.58, 8.62, 8.62, 8.65, 8.70, 8.70,  $x_{27}$

$X_k$  - zawartość tytanianu baru w  $k$ -tej próbce,  $k=1 \dots 27$

- SZEREG ROZDZIELCZY

$x_{\min}, x_{\max}$

$$x_{\min} = 8,31$$

$$x_{\max} = 8,70$$

$$r = x_{\max} - x_{\min}$$

$$r = 0,39$$

$$h = \frac{0,39}{5} \approx 0,08$$

$k$  - liczba klas dla  $n \leq 50$ :  
 $\frac{\sqrt{n}}{2} \leq k \leq \sqrt{n}$

$k$  powinno być  $\geq 5$  i  $\leq 30$

$h$  - szerokość klasy


$$h = \frac{r}{k}$$

dla  $n=27$ ,  $k=5$   $\leftarrow$  w rzeczywistości 1 klasa więcej, bo rozszerzyliśmy przedziały szerzej niż zakładane

chcemy, żeby 1. obserwacja była gdzieś w środku, nie na samym początku

klasa (i)	(8.28, 8.36]	(8.36, 8.44]	(8.44, 8.52]	(8.52, 8.60]	(8.60, 8.68]	(8.68, 8.76]
liczebność klasy $n_i$	3	4	11	4	3	2
częstość klasy $\frac{n_i}{n}$	$\frac{3}{27}$	$\frac{4}{27}$	$\frac{11}{27}$	$\frac{4}{27}$	$\frac{3}{27}$	$\frac{2}{27}$

- HISTOGRAM - graficzne przedstawienie szeregu rozdzielczego



- funkcję określonej na próbie losowej  $(X_1, X_2, \dots, X_n)$  nazywamy STATYSTYKA
- WAŻNIEJSZE STATYSTYKI:

① Średnia z próby

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad \bar{x} =$$

② Wariancja z próby

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \left( \frac{1}{n} \sum_{i=1}^n X_i^2 \right) - (\bar{X})^2$$
$$S_1^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

} zależne od autora podręcznika

③ Dyspersja z próby (odchylenie standardowe)

$$S = \sqrt{S^2} \quad S_1 = \sqrt{S_1^2}$$

④ Moment rzędu k

$$M_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

moment centralny rzędu k:  $C_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$

⑤ Współczynnik zmienności

$$v = \frac{S}{\bar{X}} \cdot 100\%$$

⑥ Mediana z próby

ustawiamy próbę  $(X_1, X_2, \dots, X_n)$  w ciąg niemalejący  $X_{(1)} \leq X_{(2)} \leq X_{(3)} \leq \dots$

$$Me = \begin{cases} X_{(\frac{n+1}{2})} & n \text{ nieparzyste} \\ \frac{X_{(\frac{n}{2})} + X_{(\frac{n}{2}+1)}}{2} & n \text{ parzyste} \end{cases}$$

⑦ Kwartył dolny  $Q_1$

$Q_1$  - mediana z obserwacji  $\leq Me$

⑧ Kwartył górny  $Q_3$


$Q_3$  - środkowa (mediana) z obserwacji  $> Me$

w przedziale  $[Q_1, Q_3]$  jest około połowa obserwacji

⑨ Odstęp międzykwartyłowy

$$IRQ = Q_3 - Q_1$$

⑩ Wykres ramkowy



Obserwacje odstające - obserwacje poza przedziałem  $[A, B]$

• obliczenia dla przykładu:

$$\bar{x} = \frac{1}{27} (8,31 + \dots + 8,70) = 8,503$$

- obliczenia dla przykładu:

$$\bar{x} = \frac{1}{27} (8,31 + \dots + 8,70) = 8,503$$

$$s^2 = \frac{1}{27} ((8,31)^2 + \dots + (8,70)^2) - (8,503)^2 = 0,011$$

$$s = 0,104$$

$$v = \frac{s}{\bar{x}} \cdot 100\% = \frac{0,104}{8,503} \cdot 100\% = 1,2\%$$

$$Me = x_{14} = 8,49$$

$$Q_1 = \frac{x_7 + x_8}{2} = 8,45$$

$$Q_3 = x_{21} = 8,58$$

$$A = \max \{ 8,31, 8,45 - \frac{3}{2} \cdot 0,13 \} = 8,31$$

$$B = \min \{ 8,7, 8,58 + \frac{3}{2} \cdot 0,13 \} = 8,7$$